

Proyecto 1

Clasificador de Objetos Astronómicos

Nombre: Fernando Patricio Palma Olea

Asignatura: Introducción a los Repositorios de Código Distribuido

Fecha: 5 de Julio de 2026

Enlace repositorio: <https://github.com/fernanaando/proyecto-repo>

Descripción del proyecto

- 1) Problema abordado: en astronomía se recopilan datos de manera continua. Debido a la masividad de esta información, resulta prácticamente imposible clasificar todas las observaciones de forma manual. El problema que soluciona este proyecto es la clasificación automatizada de estos cuerpos celestes, específicamente de galaxias, estrellas y cuásares, basándose únicamente en sus características de luz. Estas características incluyen mediciones de luz ultravioleta, verde, roja, infrarrojo cercano e infrarrojo profundo, además del análisis de su corrimiento al rojo (redshift), el cual indica la velocidad a la que el objeto se aleja de la Tierra.
- 2) Objetivo: el objetivo de este proyecto es desarrollar y comparar dos modelos predictivos capaces de clasificar de manera automática estos objetos astronómicos utilizando únicamente sus características espectrales.
- 3) Funcionalidades principales:
 - a. Análisis exploratorio de datos (EDA): procesamiento y visualización inicial del conjunto de datos.
 - b. Implementación de modelos predictivos: entrenamiento de dos modelos predictivos de clasificación, Random Forest y KNN.
 - c. Evaluación de rendimiento: cálculo de métricas de precisión y matriz de confusión para validar la eficiencia de los modelos.

Estructura del proyecto

El repositorio de este proyecto se encuentra estructurado de la siguiente manera:

- 1) La carpeta /código es el directorio principal donde se encuentra el código fuente del proyecto, en su interior está el archivo clasificador.ipynb que contiene todo el flujo de trabajo.
- 2) En la carpeta raíz del proyecto está también el archivo .gitignore y el archivo README.md que contienen los archivos y dependencias que no se debiesen subir al repositorio y la presentación al proyecto con sus instrucciones de uso y dependencias.

Evolución del desarrollo

Fase 1: Configuración y Análisis Inicial (26 al 28 de junio)

El repositorio comenzó con un **Initial commit** y la configuración base del entorno, agregando los archivos .gitignore y **README.md**, durante estos 3 días el trabajo en la rama principal **main** se centro exclusivamente en la carga de la información y el

análisis exploratorio de datos para poder entender la estructura y los tipos y distribución de los datos del dataset.

```
commit 8bfc4b1c646792a8f7f1fdf50c090296afd756d9
Author: Fernando <147350417+fernanaando@users.noreply.github.com>
Date:   Fri Jun 26 17:30:19 2026 -0400

    Initial commit

.gitignore | 429 ++++++
README.md  |   1 +
2 files changed, 430 insertions(+)
```

Ilustración 1: commit 1 (initial commit)

```
commit e714f3f35bcd9bf014ebc926de968fd1ae041fd5
Author: fernando <fernando.palma@pregrado.uoh.cl>
Date:   Fri Jun 26 17:49:01 2026 -0400

    configuración inicial, agregar .gitignore y README

.gitignore | 438 +++-----
README.md  |   3 +-
2 files changed, 11 insertions(+), 430 deletions(-)
```

Ilustración 2: configuración inicial, gitignore y README.md

```
commit 0844c674daaaea8f4505a0f05534f5cebb983099
Author: fernando <fernando.palma@pregrado.uoh.cl>
Date:   Sun Jun 28 20:45:58 2026 -0400

    analisis exploratorio de los datos (EDA)

clasificador.ipynb | 99 ++++++
1 file changed, 93 insertions(+), 6 deletions(-)
```

Ilustración 3: análisis exploratorio de datos

Fase 2: Preparación de los Datos (29 de junio)

Una vez ya entendida la estructura del dataset, se realizaron commits en la rama principal para preparar los datos para los modelos a entrenar. Se separaron las variables predictoras correspondientes a las características de la luz y se separó el dataset en subconjuntos de entrenamiento y validación.

```
commit 286fb473284254a790d7a08f6f417c763889421d
Author: fernando <fernando.palma@pregrado.uoh.cl>
Date:   Mon Jun 29 15:42:45 2026 -0400

    separacion de datos para predecir

clasificador.ipynb | 35 ++++++
1 file changed, 35 insertions(+)
```

Ilustración 4: separación de datos

```
commit 20b6bb2b35d66cdf4c975247f74ef88b34704e9
Author: fernando <fernando.palma@pregrado.uoh.cl>
Date: Mon Jun 29 16:00:24 2026 -0400

    finalizacion de preparacion de datos: division de datos train test

clasificador.ipynb | 20 ++++++-----
1 file changed, 13 insertions(+), 7 deletions(-)
```

Ilustración 5: finalización de separación de datos para predecir

Fase 3: Trabajo en Paralelo y Bifurcación (30 de junio al 2 de julio)

Luego para el desarrollo de ambos modelos predictores se realizaron dos ramas para poder trabajar cada modelo en su rama respectiva.

1. Rama **randomForest**: rama exclusiva para entrenamiento y validación de modelo random forest

```
commit 936d7e24b4826477482407eab4f1d38fc48c757f (origin/randomForest, randomForest)
Author: fernando <fernando.palma@pregrado.uoh.cl>
Date: Tue Jun 30 18:10:31 2026 -0400

    implementacion de random forest y visualizacion con la matriz de confusion

clasificador.ipynb | 110 ++++++-----
1 file changed, 99 insertions(+), 11 deletions(-)
```

Ilustración 6: rama para modelo Random Forest

2. Rama **KNN**: rama exclusiva para entrenamiento y validación de modelo KNN

```
commit b79301ab9ad15deb049bd4a0ca8f764c9f0d2366 (origin/knn, knn)
Author: fernando <fernando.palma@pregrado.uoh.cl>
Date: Thu Jul 2 17:22:53 2026 -0400

    realizacion de segundo modelo de prediccion knn

clasificador.ipynb | 123 ++++++-----
1 file changed, 113 insertions(+), 10 deletions(-)
```

Ilustración 7: rama para modelo KNN

Fase 4: Integración (Merges) y Resolución de Conflictos (3 al 5 de julio)

Con ambos modelos listos en sus respectivas ramas, se continuo con la unificación del código a la rama **main** mediante un Three-way merge. Primero se hizo un Merge con la rama **randomForest** y luego al intentar unir la rama **knn** git detectó un choque de código ya que ambas ramas habían modificado la misma parte del código principal.

```
Ⓢ (repo) fernando@ffernando:~/s9/repo/proyecto-repo$ git merge knn
Auto-merging clasificador.ipynb
CONFLICT (content): Merge conflict in clasificador.ipynb
Automatic merge failed; fix conflicts and then commit the result.
```

Ilustración 8: conflicto al intentar hacer merge con rama knn

Se tomó la decisión de dejar el modelo de randomForest como modelo definitivo para el proyecto debido a su alta eficiencia en la predicción y descartar los cambios de la rama knn. Esta decisión se basa en que el modelo de random forest obtuvo una precisión de 98% y knn de un 95%.

```

* 608debd (HEAD -> main, origin/main, origin/HEAD) estructura del proyecto
* f5f8e7e instrucciones de uso README
* 96af8b4 correccion de errores
* 551ca8f merge con rama de clasificador knn
| \
| * b79301a (origin/knn, knn) realizacion de segundo modelo de prediccion knn
* | 22fad39 merge 1
| \ \
| / /
| / /
| * 936d7e2 (origin/randomForest, randomForest) implementacion de random forest y visualizacion con la matriz de confusion
* | 305f245 descripcion de cada variable a usar
| /
| /
* 20b6bb2 finalizacion de preparacion de datos: division de datos train test
* 286fb47 separacion de datos para predecir
* 0844c67 analisis exploratorio de los datos (EDA)
* 4a56b02 analisis exploratorio inicial
* e714f3f configuracion inicial, agregar .gitignore y README
* 8bfc4b1 Initial commit

```

Ilustración 9: historial de commits con la unión de ambas ramas

Análisis del historial de git

- 1) Numero total de commits: historial completo de commits formateado en una lista en donde se aprecia el hash corto de cada commit con su mensaje y la fecha de cada commit correspondiente.

608debd	2026-07-05	fernando	estructura del proyecto
f5f8e7e	2026-07-04	Fernando	instrucciones de uso README
96af8b4	2026-07-03	fernando	correccion de errores
551ca8f	2026-07-03	fernando	merge con rama de clasificador knn
22fad39	2026-07-03	fernando	merge 1
b79301a	2026-07-02	fernando	realizacion de segundo modelo de prediccion knn
305f245	2026-06-30	fernando	descripcion de cada variable a usar
936d7e2	2026-06-30	fernando	implementacion de random forest y visualizacion con la matriz de confusion
20b6bb2	2026-06-29	fernando	finalizacion de preparacion de datos: division de datos train test
286fb47	2026-06-29	fernando	separacion de datos para predecir
0844c67	2026-06-28	fernando	analisis exploratorio de los datos (EDA)
4a56b02	2026-06-26	fernando	analisis exploratorio inicial
e714f3f	2026-06-26	fernando	configuración inicial, agregar .gitignore y README
8bfc4b1	2026-06-26	Fernando	Initial commit

Ilustración 10: historial de commits

- 2) Días con actividad: 8 días, se comenzó a trabajar el 26 de junio y se termino el 5 de julio

```
(repo) fernando@fernando:~/s9/repo/proyecto-repo$ git log --all --date=short --pretty=format:%ad | sort -u
2026-06-26
2026-06-28
2026-06-29
2026-06-30
2026-07-02
2026-07-03
2026-07-04
2026-07-05
```

Ilustración 11: días de actividad

- 3) Archivo mas modificado: el archivo mas modificado fue sin duda el **clasificador.ipynb** ya que fue el archivo que concentraba todo el código del proyecto y al que se le unieron todos los cambios de las dos ramas creadas.
- 4) Commits mas relevantes: por el desarrollo del proyecto los commits más importantes son los siguientes:
 - a. Commit **20b6bb2** ya que fue el commit que finalizo la división de datos ara entrenamiento y validación
 - b. Commit **936d7e2** ya que fue el commit en donde se implemento el modelo random forest junto con la visualización de sus métricas de predicción.
 - c. Commit **b79301a** ya que fue el commit que incluyo la realización del segundo modelo de predicción, KNN.
- 5) Ramas utilizadas: el proyecto se llevo a cabo en 3 ramas:

```
(repo) fernando@ffernando:~/s9/repo/proyecto-repo$ git branch
knn
* main
randomForest
```

Ilustración 12: ramas utilizadas

- 6) Merges realizados: se realizaron 2 merges, uno con la rama randomForest y el segundo con la rama knn

```
(repo) fernando@ffernando:~/s9/repo/proyecto-repo$ git log --oneline --merges
551ca8f merge con rama de clasificador knn
22fad39 merge 1
```

Ilustración 13: merges realizados

- 7) Evidencia del three-way merge: primero se hizo un merge de la rama randomForest a la rama main y posteriormente de la rama knn a la rama main

```
* 551ca8f merge con rama de clasificador knn
| \
| * b79301a (origin/knn, knn) realizacion de segundo modelo de prediccion knn
| * | 22fad39 merge 1
| \
| /
| * 936d7e2 (origin/randomForest, randomForest) implementacion de random forest y visualizacion con la matriz de confusion
| * | 305f245 descripcion de cada variable a usar
| /
| * 20b6bb2 finalizacion de preparacion de datos: division de datos train test
```

Ilustración 14: three-way merge

Análisis de integración de cambios

- 1) Rama main: es la rama principal del proyecto, corresponde a la base del proyecto en donde se aloja la configuración inicial, la documentación y el código base del modelo entrenado. El objetivo de esta rama es unificar la carga del

dataset, el análisis exploratorio del dataset y la separación de los conjuntos de entrenamiento y validación, sirviendo como punto de partida antes de aplicar cualquier modelo de predicción.

- 2) Rama randomforest: es una rama de desarrollo secundaria que salió de la rama main y los datos ya procesados. El objetivo de esta rama es exclusivamente la implementación y entrenamiento del modelo de predicción random forest permitiendo desarrollar este modelo y generar sus métricas de evaluación.
- 3) Rama knn: corresponde a una segunda rama secundaria que nace a partir de los datos ya separados en la rama main. El objetivo de esta rama es implementar y evaluar un modelo knn para luego compararlo con el modelo de randomforest y ver cual obtiene una precisión mejor.

Análisis de métricas

- 1) Contributors: este grafico de contribuciones muestra un desarrollo del proyecto de manera progresiva e incremental, registra un total de 12 commtis a lo largo del periodo con un volumen de codigo positivo, tiene 1356 lineas de codigo agregadas versus las 867 lineas eliminadas. La distribucion del trabajo tiene una carga inicial moderada que aumenta con el pasar de los dias, logrando un maximo de actividad durante la semana del 29 de junio, registrando 7 contribuciones en ese rango de dias.




Ilustración 15: grafico de fechas y commits por dia

- 2) Code frequency: este grafico representa la frecuencia de codigo, muestra las distintas fases del ciclo de vida del proyecto mediante las adiciones (color verde) y las eliminaciones (color rojo). Durante la semana del 22 de junio se puede observar un alto volumen de eliminaciones y agregaciones, teniendo un aproximado de 550 y 450 respectivamente. Luego, la semana del 29 de junio se muestra una etapa donde predominan las inserciones de codigo con un minimo de eliminaciones. Finalmente. La semana del 6 de julio se vuelve

a registrar un empate en cuanto a las eliminaciones y agregaciones de código al proyecto, lo que coincide con la fecha en donde se realizó el three-way merge.



Ilustración 16: líneas agregadas y eliminadas

- 3) Network graph: el gráfico de red proporciona una representación del flujo de trabajo ramificado del proyecto. Inicialmente, se puede observar un historial lineal solo en la rama main entre el 26 y 29 de junio, etapa en donde solo se basó en el análisis exploratorio de los datos y la separación de estos. Luego, el gráfico muestra una separación del repositorio con la rama randomForest el 30 de junio y la rama knn el 2 de julio, lo que representa el desarrollo de ambos modelos. El momento más crucial para el proyecto fue en el día 3 de julio, donde las flechas muestran una integración de ambas ramas de vuelta a la rama main mostrando así la ejecución de integraciones tipo three-way merge.




Ilustración 17: línea de tiempo de ramas

Reflexión final

El desarrollo de este proyecto me permitió entender que git es una herramienta necesaria para gestionar proyectos de software, ya que ayuda a mantener el orden y el historial de cada cambio que realizamos. Trabajar con Commits me enseñó a avanzar de forma progresiva mientras que el uso de ramas me dio la oportunidad de experimentar cambios e integraciones en paralelo al código que ya tenía bueno sin arriesgar de arruinar su implementación. Finalmente, integrar todo el trabajo mediante un three-way merge y tener que resolver un conflicto de forma manual me ayudó a comprender que estos errores son parte del desarrollo y que casi siempre existirán y que eso no significa que este mal y también que llevar un buen historial del proyecto no solo sirve para respaldar los archivos, sino que también sirven para documentar las decisiones tomadas durante el desarrollo y la evolución del proyecto.